

基于 Olist 数据集的电商用户行为分析与复购预测研究

摘要

随着电子商务市场竞争日趋激烈，精准识别高复购潜力用户已成为平台精细化运营的关键环节。本文基于 Kaggle 平台公开的 Olist Brazilian E-Commerce Dataset，整 6 张核心数据表，以 2016 年 9 月至 2018 年 2 月为历史特征窗口、2018 年 3 月至 8 月为预测窗口，开展电商用户行为分析与复购预测研究。

研究首先对原始数据进行探索性数据分析（EDA），识别出缺失值、异常值及时间逻辑矛盾等质量问题；随后通过系统化的数据清洗、多表集成与 ETL 流程，构建包含时间、客户、商品、支付四个维度表与订单事实表的星型数据仓库。在此基础上完成 OLAP 多维分析，并基于 RFM 模型结合 KMeans 聚类将 55,507 个用户划分为沉睡用户、新客与潜力活跃用户、高频次用户及大额客单用户四类群体。进一步从历史窗口中提取购买频率、平均订单金额、总消费金额、购买间隔等 8 项行为特征，构建用户未来 6 个月复购标签，分别采用 Logistic Regression、Random Forest 和 XGBoost 建立预测模型。

实验结果表明，Random Forest 模型准确率达到 0.8530，在三类模型中最高；Logistic Regression 召回率为 0.3233，在捕捉潜在复购用户方面表现最优；XGBoost 准确率为 0.7419。特征重要性分析进一步揭示，平均订单金额、总消费金额与购买间隔是影响用户复购决策的核心驱动因素。本研究为电商平台制定差异化用户运营与精准营销策略提供了数据驱动的决策支持。

关键词：复购预测；星型数据仓库；RFM 用户分层；随机森林；XGBoost

目录

1. 引言	1
1.1 研究背景与意义	1
1.2 研究内容与技术路线	1
2. 问题定义与数据理解	2
2.1 业务问题定义	2
2.2 数据来源介绍	2
2.3 数据集结构分析	3
2.4 时间窗口划分设计	3
3. 数据预处理与仓库设计	4
3.1 数据概况与探索性分析（EDA）	4
3.2 数据清洗	6
3.3 数据集成与 ETL 流程	7
3.4 数据仓库设计	8
3.5 特征工程	9
4. 数据可视化与 OLAP 分析	10
4.1 描述性统计分析	10
4.2 商品品类与区域市场分析	11
4.3 支付行为分析	12
4.4 RFM 用户价值分析与聚类分层	13
4.5 OLAP 多维分析总结	15
5. 模型构建与实现	16
5.1 预测任务定义	16
5.2 特征编码与数据集划分	16
5.3 Logistic Regression 模型构建	17
5.4 Random Forest 模型构建	18
5.5 XGBoost 模型构建	18
5.6 参数优化设计与实现	19
6. 结果评估与比较	21
6.1 评价指标说明	21
6.2 三模型结果比较	21
6.3 ROC 曲线和 PR 曲线分析	23
6.4 特征重要性分析	24
7. 结论与讨论	26
7.1 研究结论	26
7.2 局限性分析	26

1. 引言

1.1 研究背景与意义

近年来，全球电商市场规模持续扩张，但流量红利消退使平台竞争焦点从“获取新客”转向“经营存量”。在这一背景下，用户复购率成为衡量平台健康度的核心指标^[1]——维护老客户的成本远低于获取新客户，而高复购用户往往贡献了平台绝大部分营收。如何基于历史交易数据精准识别复购潜力用户并制定差异化运营策略，已成为电商企业提升竞争力的关键命题。数据挖掘技术为此提供了有效路径：通过对海量交易数据进行清洗、建模与多维分析，可挖掘用户消费行为的潜在规律，实现购买意图预测。

巴西作为拉美最大电商市场，其 Olist 平台积累了涵盖订单、客户、商品、支付等多维度的完整交易数据，为开展用户行为分析与复购预测研究提供了高质量的数据基础。本研究基于 Kaggle 公开的 Olist Brazilian E-Commerce Dataset，系统开展数据挖掘实践：通过构建星型数据仓库与 RFM 聚类模型实现用户价值分层，并分别采用 Logistic Regression、Random Forest 和 XGBoost 建立复购预测模型，探索从原始交易数据到业务决策支持的完整技术路径。研究成果可为平台实施精准营销、优化商品结构与改善物流体验提供直接的数据支撑。

1.2 研究内容与技术路线

本研究围绕“电商用户行为分析与购买预测”这一核心主题，系统开展以下工作：首先，对 Olist 平台 6 张核心业务表进行数据清洗与集成，处理缺失值、异常值及时间逻辑错误，并构建星型数据仓库；其次，基于清洗后的数据进行探索性数据分析与 OLAP 多维分析，从时间、地域、品类、支付方式等维度洞察业务规律；再次，利用 RFM 模型结合 KMeans 聚类算法进行用户价值分层，构建用户画像体系；然后，从历史窗口（2016 年 9 月至 2018 年 2 月）中提取用户行为特征，构造未来 6 个月复购标签，形成包含 55,507 个用户样本、8 项核心特征的建模数据集；最后，分别采用 Logistic Regression、Random Forest 和 XGBoost 建立复购预测模型，通过准确率、召回率、F1 值及 AUC 等多维度指标进行评估对比，并开展特征重要性分析。

本研究的技术路线可概括为以下流程：首先从 Kaggle 平台采集 Olist Brazilian E-Commerce Dataset 原始数据，经过数据清洗（缺失值填充、异常值剔除、重复值处理、时间逻辑校验）与数据集成（多表关联、类别翻译）后，设计并构建星型数据仓库；在此基础上开展 EDA 分析，从订单状态、月度趋势、支付分布等维度进行初步探索；随后进入 OLAP 分析与 RFM 用户价值分析阶段，通过

KMeans 聚类实现用户分层；接着进行特征工程，从历史窗口中提取用户行为特征并构造复购标签，形成 `final_model_dataset` 建模数据集；之后分别训练 Logistic Regression、Random Forest 和 XGBoost 三种模型，采用网格搜索进行超参数优化；最终通过混淆矩阵、ROC 曲线、Precision-Recall 曲线及特征重要性分析对模型进行全面评估与比较，提炼业务洞察并形成决策建议。

2. 问题定义与数据理解

2.1 业务问题定义

本研究面向巴西 Olist 电商平台的实际运营需求，聚焦于两个相互关联的核心问题：一是如何基于用户历史交易数据构建精准的用户画像体系，实现对不同价值层级用户的有效识别；二是如何利用用户过往行为特征，预测其在未来特定时间窗口内是否会发生再次购买行为。这两个问题分别对应数据挖掘中的聚类分析与分类预测任务，其解决结果可直接服务于平台的用户分层运营与精准营销决策。

从业务角度看，电商平台的用户群体呈现出显著的分化特征：大部分用户仅完成单次购买后便不再活跃，而少数高价值用户则持续贡献复购订单。若平台无法提前识别哪些用户具有复购潜力，营销资源将被低效地分散投放，导致运营成本攀升而转化效果不佳。因此，本研究将预测目标设定为二分类问题——即判断用户在预测窗口内是否复购（`repurchase_label=1` 表示复购，`repurchase_label=0` 表示未复购），同时通过 RFM 聚类分析揭示用户群体的内在结构，为差异化运营策略提供依据。

2.2 数据来源介绍

- **数据集名称:** Brazilian E-Commerce Public Dataset by Olist
- **获取方式:** <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>
- **时间范围:** 数据时间跨度为 2016-2018 年，包含共 99441 条原始订单记录。
- **数据类型:** 结构化表格数据，文件格式为 CSV。
- **核心数据:** `olist_orders_dataset`（订单主表）、`olist_customers_dataset`（客户信息表）、`olist_order_items_dataset`（订单商品明细表）和 `olist_products_dataset`（商品信息表）。`orders` 表记录订单级别的交易事件，`customers` 表提供用户身份与地理信息，`order_items` 表承载订单与商品的关联关系及价格信息，`products` 表则补充商品属性。
- **辅助数据:** `olist_order_payments_dataset`（订单支付表）和 `product_category_name_translation.csv`（商品类别翻译表）。

payments 表记录了每笔订单的支付方式与分期信息，对于分析用户支付偏好及消费能力具有重要价值；translation 表则将商品类别名称从葡萄牙语翻译为英语，便于后续进行跨语言的品类分析与可视化展示。

2.3 数据集结构分析

各数据表的关键字段与功能如表 2-1 所示。

表 2-1 核心数据表字段结构

数据表	关键字段	字段作用
olist_orders_dataset	order_id, customer_id, order_purchase_timestamp, order_delivered_customer_date, order_status	订单唯一标识、下单用户、购买时间、实际送达时间、订单状态
olist_customers_dataset	customer_id, customer_unique_id, customer_city, customer_state	订单级用户 ID、全局唯一用户 ID、所在城市、所在州
olist_order_items_dataset	order_id, product_id, price, freight_value	所属订单、商品 ID、商品单价、运费
olist_products_dataset	product_id, product_category_name, product_weight_g, product_length_cm, product_height_cm, product_width_cm	商品 ID、类别名称、重量、长、高、宽
olist_order_payments_dataset	order_id, payment_type, payment_installments, payment_value	所属订单、支付方式、分期数、支付金额
product_category_name_translation	product_category_name, product_category_name_english	葡语类别名、英语类别名

以 orders 表为中心，通过 order_id 与 order_items 表、payments 表关联，使得单条订单可对应多条商品记录，支持一个订单可有多笔支付记录，通过 customer_id 与 customers 表关联，实现每个订单对应一个客户；同时 order_items 表通过 product_id 与 products 表关联，多个订单可对应同一商品；products 表通过 product_category_name 与 translation 表关联，完成商品类别名称从葡萄牙语到英语的转换。

2.4 时间窗口划分设计

时间窗口的合理划分是确保预测模型有效性的关键环节。本研究将整体数据时间范围划分为两个互不重叠的窗口：历史特征窗口

（2016 年 9 月至 2018 年 2 月）与预测标签窗口（2018 年 3 月至 2018 年 8 月）。这种划分方式的核心逻辑在于严格避免数据泄露——即确保用于预测的特征信息全部来源于目标事件发生之前，防止“用未来预测未来”的逻辑谬误。

具体而言，历史窗口用于提取用户的行为特征，包括购买频率、平均订单金额、总消费金额、购买间隔、平均分期数、偏好支付方式、偏好商品类别以及平均配送天数等 8 项指标。这些特征反映了用户在观察期内的消费习惯与平台互动模式。预测窗口则用于构造监督学习的标签变量：若用户在 2018 年 3 月 1 日至 2018 年 8 月 31 日期间产生了新的订单，则标记为复购用户（repurchase_label=1），否则标记为未复购用户（repurchase_label=0）。

选择 2018 年 3 月 1 日作为切分点，主要基于以下考量：首先，该时间点处于数据集时间范围的中间偏后位置，既保证了历史窗口具有充足的数据积累以提取稳定的行为特征，又确保预测窗口具有 6 个月的完整时长以观察用户的复购行为；其次，从业务季节性角度，3 月至 8 月涵盖了巴西的母亲节、父亲节等重要促销节点，用户的购买行为具有一定的代表性；最后，该切分点使得最终建模数据集包含 55,507 个有效用户样本，在样本规模与特征稳定性之间取得了平衡。

3. 数据预处理与仓库设计

3.1 数据概况与探索性分析（EDA）

在数据清洗之前，首先对原始数据进行探索性数据分析（Exploratory Data Analysis, EDA），以全面了解数据质量、分布特征及潜在问题，为后续处理策略的制定提供依据。




图 3-1 订单状态分布

图 3-1 展示了订单状态分布情况。从图中可以观察到，"delivered"（已送达）状态的订单占据绝对主导地位，表明平台订单完成率较高，物流履约能力整体可靠。同时，图中也显示了"shipped"（已发货）、"canceled"（已取消）及"unavailable"（不可用）等状态的少量订单，反映了库存缺货、支付失败或用户主动取消等异常因素。




图 3-2 月度订单量与销售额趋势

图 3-2 采用双轴图展示了 2016 年 9 月至 2018 年 2 月期间的月度订单量与销售额变化趋势。从图中可以观察到，平台订单量与销售额呈现整体上升态势，尤其在 2017 年下半年增长斜率显著加大，表明 Olist 平台在此期间处于快速扩张阶段。同时，月度曲线存在一定波动，部分月份出现订单量回落，可能与巴西当地的节假日安排、促销活动周期或季节性消费规律有关。从业务角度看，识别订单波动的周期性特征，有助于平台在业务低谷期提前部署营销策略以平滑收入曲线，在高峰期则加强供应链备货与物流运力调配。




图 3-3 订单支付金额分布

图 3-3 展示了支付金额的分布特征。从图中可以观察到，支付金额呈现典型的右偏分布形态，峰值集中在低金额区间，随着金额增大频数迅速衰减，形成明显的长尾结构。这一现象符合电商消费的普遍规律：日常快消品、小件商品构成了交易的主体，而家电、家具等高价商品仅偶尔产生大额订单。




图 3-4 数据字段缺失率分布

图 3-4 统计了各数据表的字段缺失率分布。图 3-4 展示了各数据表字段的缺失率分布情况。从图中可以观察到，缺失问题主要集中在两个维度：一是 **orders** 表的时间字段，其中 `order_delivered_customer_date`（实际送达客户日期）缺失率高达 2.98%，`order_delivered_carrier_date`（发货日期）缺失率为 1.79%；二是 **products** 表的属性字段，`product_photos_qty` 等字段缺失率为 1.85%，而物理属性字段缺失率仅为 0.01%。

综合 EDA 阶段的发现，原始数据存在以下主要问题需要解决：一是缺失值问题，分布于 **products** 表的属性字段与 **orders** 表的时间字段；二是异常值问题，`price` 与 `freight_value` 字段存在负值及极端离群值；三是时间字段问题，字符串格式无法直接参与时间运算，且存在逻辑矛盾记录；四是多表分散存储，需要通过数据集成构建统一的分析视图。

3.2 数据清洗

针对 EDA 阶段识别出的数据质量问题，本研究从缺失值处理、重复值检查、异常值剔除及时间逻辑校验四个方面进行数据清洗。

（1）缺失值处理

对于 **products** 表中的数值型字段（`product_weight_g`、`product_length_cm`、`product_width_cm` 等），采用中位数填充，以避

免极端值对中心趋势的干扰；对于 `product_category_name` 这一类别型字段，将缺失值统一标记为“`unknown_category`”，既保留了记录完整性，又便于后续识别未分类商品。`orders` 表中存在少量订单状态为“`delivered`”但缺失实际送达时间的记录，此类数据属于业务逻辑矛盾，直接删除。

（2）重复值检查

重复值处理针对 `orders`、`customers`、`order_items` 和 `payments` 四张表进行全局检查，删除完全重复的记录行，确保每笔交易、每个用户、每个订单项在数据集中具有唯一性。

（3）异常值处理

异常值处理分为两个步骤。首先删除 $\text{price} < 0$ 和 $\text{freight_value} < 0$ 的记录，这类负值违背商业常识。随后采用 IQR（四分位距）方法对价格数据进行异常检测，设定边界为 $\text{Lower} = Q1 - 3 \times \text{IQR}$ 和 $\text{Upper} = Q3 + 3 \times \text{IQR}$ ，超出该范围的极端高价订单被剔除，以消除离群值对统计分析与模型训练的干扰。

（4）时间逻辑检查

本研究严格确保业务时间顺序的正确性：购买时间应不晚于审核时间，发货时间应不晚于签收时间。违反上述逻辑的数据记录被识别并删除，以确保时间相关特征的计算准确无误。

3.3 数据集成与 ETL 流程

在完成清洗后，需将分散于各表中的信息整合为统一的分析视图。以 `orders` 表为核心，通过 `order_id` 与 `order_items` 表关联，获取订单包含的商品及价格信息；通过 `order_id` 与 `payments` 表关联，获取支付方式和金额信息；通过 `customer_id` 与 `customers` 表关联，获取用户的地理与身份信息；通过 `product_id` 将 `order_items` 表与 `products` 表关联，获取商品的物理属性与类别信息；最后通过 `product_category_name` 将 `products` 表与 `translation` 表关联，完成类别名称的语言转换。构建包含用户、订单、商品、支付、物流等完整信息的业务宽表。

整个 ETL（Extract-Transform-Load）流程概括为三个阶段：数据抽取阶段从原始 CSV 文件中读取六张数据表；数据转换阶段依次执行数据清洗、类别翻译、多表关联、时间切分与特征计算等操作；数据加载阶段采用星型模型设计，将清洗后的数据加载至事实表（`fact_orders`）和客户、商品、支付、时间等维度表中，形成支持 OLAP 分析和机器学习建模的数据仓库，为后续用户行为分析与复购预测提供统一、可靠的数据基础。

3.4 数据仓库设计

为支持高效的多维分析，本研究采用星型模型（Star Schema）^[2]构建数据仓库。星型模型以事实表为中心，周围环绕多个维度表，具有结构简洁、查询效率高的特点，适用于 OLAP 场景下的多维透视分析^[3]。




图 3-5 星型结构图

订单事实表（fact_orders）作为星型模型的核心，记录了每笔订单的关键度量信息，包含 order_id、customer_id、product_id、order_purchase_timestamp、price、freight_value、payment_value、payment_type 和 payment_installments 共 9 个字段，数据规模为 118,159 行×9 列。该表是后续销售额统计、订单量分析等 OLAP 操作的数据基础。

客户维度表（dim_customer）描述用户的身份信息与地理分布，包含 customer_id、customer_unique_id、customer_city 和 customer_state 共 4 个字段，数据规模为 99,441 行×4 列。其中 customer_unique_id 作为全局唯一标识，用于准确识别独立用户，避免同一用户通过不同订单产生的重复计数。

商品维度表（dim_product）提供商品的类别归属与物理属性信息，包含 product_id、product_category_name_english、product_weight_g、product_length_cm、product_height_cm 和 product_width_cm 共 6 个字段，数据规模为 32,951 行×6 列。经过类别翻译后的英文类别名便于

可视化展示。

支付维度表（`dim_payment`）描述支付方式的类别与分期特征，包含 `payment_type` 和 `payment_installments` 共 2 个字段，数据规模为 28 行×2 列。该表行数较少，但记录了支付类型与分期数的所有有效组合，是分析用户支付偏好的重要维度。

时间维度表（`dim_time`）从订单时间中抽取多粒度时间信息，包含 `time_id`、`purchasetime`、`year`、`month`、`day`、`weekday` 和 `hour` 共 7 个字段，数据规模为 98,843 行×7 列。通过预计算年、月、日、星期、小时等维度，支持时间维度的上卷（Roll-up）与下钻（Drill-down）分析，显著提升时间序列查询的效率。

3.5 特征工程

特征工程是连接原始数据与机器学习模型的桥梁。本研究从历史窗口（2016 年 9 月至 2018 年 2 月）中提取 8 项用户行为特征，具体构造逻辑如下。

`purchase_frequency`（购买频率） 统计用户在历史窗口内的订单数量，直接反映用户与平台的互动频次。该特征取值为正整数，数值越大表明用户活跃度越高。

`avg_order_value`（平均订单金额） 计算用户历史订单金额的平均值，衡量用户的单次消费水平。计算公式为历史窗口内所有订单 `payment_value` 之和除以订单数，该指标对于识别高消费潜力用户具有重要参考价值。

`total_spending`（总消费金额） 累计用户在历史窗口内的全部消费支出，是用户价值评估的核心指标。与平均订单金额相结合，可区分“高频低额”与“低频高额”两类不同的消费模式。

`purchase_interval`（购买间隔） 衡量用户相邻两次购买之间的平均时间间隔（以天为单位）。对于仅有一次购买记录的用户，该特征赋值为 365 天，表示其购买周期至少为一年。该特征能够有效区分习惯性复购用户与偶发性购买用户。

`avg_installments`（平均分期数） 基于 `payments` 表计算用户历史订单的平均支付分期数，反映用户的消费信贷偏好与支付能力。分期数较高的用户往往对价格敏感度较低，或倾向于大额消费。

`favorite_payment`（偏好支付方式） 识别用户历史订单中出现频率最高的支付方式，包括 `credit_card`、`boleto`、`voucher` 和 `debit_card` 等类别。不同支付方式背后对应着不同的用户群体特征与消费习惯。

`favorite_category`（偏好商品类别） 统计用户购买次数最多的商品品类，揭示用户的兴趣偏好与消费需求导向，为品类关联营销提供依据。

avg_delivery_days（平均配送天数） 计算从发货到签收的平均时长，反映用户的物流体验。较长的配送时间可能降低用户满意度，进而影响其复购意愿。

在上述 8 项特征的基础上，结合用户唯一标识 **customer_unique_id** 与复购标签 **repurchase_label**，形成最终的建模数据集。该数据集共包含 55,507 条用户记录、10 个字段，字段结构如表 3-1 所示。

表 3-1 最终建模数据集字段结构

字段名	数据类型	非空记录数	说明
customer_unique_id	object	55,507	用户全局唯一标识
purchase_frequency	int64	55,507	历史窗口内购买次数
avg_order_value	float64	55,507	平均订单金额（元）
total_spending	float64	55,507	总消费金额（元）
purchase_interval	float64	55,507	平均购买间隔（天）
avg_installments	float64	55,507	平均分期数
favorite_payment	object	55,507	偏好支付方式
favorite_category	object	55,507	偏好商品类别
avg_delivery_days	float64	55,507	平均配送天数
repurchase_label	int32	55,507	复购标签（0/1）

复购标签的分布呈现出极度不平衡的特征：未复购用户（**repurchase_label = 0**）共 54,844 人，复购用户（**repurchase_label = 1**）仅 663 人，正负样本比例约为 82.7:1。这一分布与电商行业的实际业务场景高度吻合——绝大多数用户完成首单后便不再活跃，仅少数用户形成持续复购。然而，极度不平衡的样本分布也为后续的分类模型训练带来了严峻挑战：模型容易倾向于将大多数样本预测为多数类（未复购），以换取整体准确率的提升，却牺牲了对少数类（复购用户）的识别能力。

4. 数据可视化与 OLAP 分析

4.1 描述性统计分析

对最终建模数据集进行描述性统计分析，可以揭示用户行为特征的整体分布规律。表 4-1 展示了各项数值型特征的统计概要。

表 4-1 建模数据集描述性统计

特征	均值	标准差	最小值	25%分位数	中位数	75%分位数	最大值
purchase_frequency	1.03	0.21	1	1	1	1	10
avg_order_value	155	213.05	1.86	60.05	102.03	172.33	13664.08
total_spending	204.10	503.06	10.07	63.27	111.22	200.04	45256
purchase_interval	355.26	56.19	0	365	365	365	454
avg_installments	2.97	2.74	1	1	2	4	24
avg_delivery_days	13.18	10.13	0	7	11	16	209

从统计结果可以观察到几个显著特征：`purchase_frequency` 的均值仅为 1.03，中位数和 75%分位数均为 1，表明绝大多数用户在历史窗口内仅完成了一次购买，平台面临严重的用户留存挑战。`purchase_interval` 的中位数和 75%分位数均为 365 天，这进一步印证了大部分用户缺乏复购行为的事实——对于单次购买用户，其购买间隔被设定为历史窗口的全长。`avg_order_value` 的标准差（213.05）远大于均值（155），说明用户消费水平差异悬殊，存在明显的长尾分布特征。`avg_delivery_days` 的最大值达到 209 天，反映出部分订单存在严重的配送延迟问题，这可能成为影响用户复购意愿的负面因素。

4.2 商品品类与区域市场分析




图 4-1 商品类别销售额 Top10

图 4-1 展示了销售额排名前十的商品类别分布。从图中可以识别出平台的核心优势品类，这些头部品类贡献了平台的主要营收，是供应链资源投入与营销预算分配的重点对象。同时，头部品类与长尾品类之间的销售额差距显著，反映出平台商品结构存在一定的不均衡性。对于排名靠后的品类，平台需要评估其增长潜力——若属于新兴品类，可通过流量扶持培育市场；若长期低迷，则需考虑优化商品结构，将运营资源向高价值品类倾斜。




图 4-2 客户州订单量 Top10

图 4-2 呈现了客户所在州（State）的订单量 Top10 排名。从图中可以看出，订单量高度集中于少数几个经济发达的州，这与巴西的人口分布与经济发展格局基本吻合。平台可针对高订单量地区加强仓储布局与末端配送网络建设，缩短配送时效以提升用户体验；针对低渗透率地区则可开展区域性促销活动，挖掘增量市场空间。

4.3 支付行为分析

图 4-4 比较了不同支付方式下月度平均订单金额的变化趋势，涉及 **credit_card**（信用卡）、**boleto**（银行转账）、**voucher**（优惠券）和 **debit_card**（借记卡）四类主要支付渠道。




图 4-3 不同支付方式的月度平均订单金额

从图中可以观察到，**credit_card** 支付订单的平均金额普遍高于其他支付方式，这与信用卡用户的消费能力和支付习惯密切相关——信用卡用户通常对价格敏感度较低，且更倾向于利用分期功能进行

大额消费。**boleto** 支付订单金额相对稳定，反映了该支付方式在巴西市场的普及度与受众特征，其用户群体消费行为较为稳健。**voucher** 支付的订单金额波动较大，可能与促销活动期间优惠券的集中发放有关，该类用户对价格促销较为敏感。**debit_card** 支付订单金额相对较低，表明借记卡用户群体可能更为注重预算控制与即时支付。

上述分析对业务运营具有指导意义：针对 **credit_card** 用户，可主推高客单价商品与分期免息服务；针对 **boleto** 用户，应优化支付流程的便捷性以降低弃单率；针对 **voucher** 用户，可设计阶梯式优惠券策略以提升复购转化；针对 **debit_card** 用户，则应重点推荐性价比商品与限时折扣活动。

4.4 RFM 用户价值分析与聚类分层

RFM 模型是客户关系管理中的经典分析框架^[4]。本研究基于 Recency（最近一次购买距观察日的天数）、Frequency（购买频次）和 Monetary（总消费金额）三个维度，对用户价值进行量化评估。




图 4-4 RFM 指标分布

图 4-4 分别展示了 R、F、M 三个维度的分布特征，从中可以识别出明显的长尾结构——大多数用户集中在低频次、低金额、高间隔区域，而高价值用户仅构成极少数尾部群体。

为确定最佳聚类数目，本研究采用肘部法（Elbow Method）^[5]基于 SSE（Inertia）指标进行判定。随着聚类数 K 的增加，SSE 呈下降趋势，但在 K=4 处曲线斜率出现明显拐点，此后下降趋缓。综合考虑，最终选定 K=4 作为聚类数目。随后，将 RFM 三维特征通过 PCA 降至二维进行可视化展示，图 4-6 呈现了聚类结果的二维散点分布，四类群体在特征空间中形成了相对清晰的分离边界。




图 4-5 肘部曲线




图 4-6 PCA 降维散点图

依据各类别在 Recency、Frequency、Monetary 三个维度上的均值特征，本研究构建了四类用户画像。表 4-2 汇总了聚类结果。

表 4-2 RFM 用户分层结果汇总

聚类 标签	平均 Recency	平均 Frequency	平均 Monetary	用户数	用户占比	群体命名
3	120.93	1.07	20686.55	14	0.03%	大额客单用户
2	136.63	2.11	412.46	1720	3.10%	高频次用户
0	279.25	1.00	193.07	20780	37.44%	沉睡用户
1	79.68	1.00	191.49	32993	59.44%	新客与潜力活跃用户

从表 4-2 可以清晰地识别出四类用户的差异化特征与运营策略方向：

大额客单用户（Cluster 3）数量极少，仅 14 人，占比 0.03%，但平均消费金额高达 20686.55 元，远超其他群体。这类用户虽然购买频次不高（平均 1.07 次），但单次消费金额极高。针对此类用户，平台应提供专属客服通道、优先配送及定制化服务，确保其高消费体验。

高频次用户（Cluster 2）共 1720 人，占比 3.10%，平均购买频次为 2.11 次，平均消费金额 412.46 元，最近一次购买距观察日约 136.63 天。这类用户是平台的核心客群，已形成稳定的复购习惯。运营策略应聚焦于会员体系建设、积分奖励与专属折扣，进一步巩固其忠诚度并提升客单价。

沉睡用户（Cluster 0）共 20780 人，占比 37.44%，平均 Recency 高达 279.25 天，购买频次为 1.00 次，平均消费金额 193.07 元。这类用户完成首单后长期未再活跃，可能已流失。对于该群体，平台可尝试通过大额优惠券、短信召回等唤醒策略进行挽回，但需严格控制投入成本，避免资源浪费在低响应率人群上。

新客与潜力活跃用户（Cluster 1）共 32993 人，占比 59.44%，是平台用户群体的主体。其平均 Recency 为 79.68 天，购买频次为 1.00 次，平均消费金额 191.49 元。这类用户近期仍有平台访问或购买行为，但尚未形成复购习惯，是平台最具转化潜力的群体。运营重点应放在个性化推荐、首次复购激励及购物体验优化上，引导其向高频次用户转化。

4.5 OLAP 多维分析总结

基于构建的星型数据仓库，本研究从时间、地域、品类、支付等多个维度开展了 OLAP 多维透视分析。通过事实表与维度表的关联，实现了对销售额、订单量、用户量等核心指标的上卷、下钻与切片操作，验证了星型模型在支持高效多维查询方面的结构优势。

综合上述分析，可以归纳出 Olist 平台用户行为的几项规律：第一，用户复购率极低，超过 96% 的用户仅完成单次购买，平台面临严峻的用户留存挑战；第二，用户消费水平差异显著，存在少量高价值大额客单用户与海量低消费新客的两极分化；第三，信用卡是平台高价值消费的主力支付方式，其用户群体消费能力最强；第四，商品品类结构不均衡，头部品类集中了大部分销售额；第五，配送时效存在较大波动，极端延迟可能影响用户体验与复购意愿。

5. 模型构建与实现




图 5-1 模型架构图

5.1 预测任务定义

本研究的预测任务属于监督学习框架下的二分类问题。给定用户的历史行为特征，预测其在未来 6 个月预测窗口（2018 年 3 月至 2018 年 8 月）内是否会再次发生购买行为。目标变量为复购标签 `repurchase_label`，其中 `repurchase_label=1` 表示用户在未来窗口内发生复购，`repurchase_label=0` 表示未发生复购。

输入特征向量 $\mathbf{X} = (x_1, x_2, \dots, x_8)$ 包含 8 个维度：购买频率（`purchase_frequency`）、平均订单金额（`avg_order_value`）、总消费金额（`total_spending`）、购买间隔（`purchase_interval`）、平均分期数（`avg_installments`）、偏好支付方式（`favorite_payment`）、偏好商品类别（`favorite_category`）以及平均配送天数（`avg_delivery_days`）。输出变量为 $y \in \{0,1\}$ 。模型的核心目标是学习从特征空间到标签空间的映射函数 $f: \mathbb{R}^8 \rightarrow \{0,1\}$ ，使得对于任意用户，模型能够基于其历史行为给出准确的复购概率估计或类别判断。

5.2 特征编码与数据集划分

由于 `favorite_payment`（偏好支付方式）和 `favorite_category`（偏

好商品类别)属于类别型变量,无法直接输入数值计算型机器学习模型,因此采用 LabelEncoder^[6]进行数值编码。LabelEncoder 的原理是将每个类别标签映射为一个唯一的整数,例如将 credit_card 映射为 0、boleto 映射为 1 等。这种编码方式适用于类别间无明确序关系的情况,且实现简单、计算效率高。LabelEncoder 编码后的数值在数学上具有顺序性,但模型训练过程中若将该数值直接作为连续变量处理,可能引入虚假的顺序假设。考虑到本研究中类别变量仅 2 个,且决策树类模型对编码方式不敏感,LabelEncoder 在本场景下是合理的选择。

数据集划分采用 train_test_split 方法,设置 test_size=0.2,即按照 80%训练集与 20%测试集的比例进行划分。选择该比例的原因在于:训练集需要足够的样本量以保证模型参数估计的稳定性,测试集则需要一定的规模以提供可靠的性能评估。对于本研究的 55,507 个样本,80%对应约 44,405 个训练样本,20%对应约 11,102 个测试样本。

划分时设置了 stratify=y 参数,该参数确保训练集与测试集中的正负样本比例与原始数据集保持一致。由于复购标签极度不平衡,若不采用分层抽样,随机划分可能导致某一子集中正样本过少甚至缺失,进而使模型训练与评估产生偏误。分层抽样有效保障了训练集与测试集在类别分布上的一致性,为后续模型对比提供了公平的基础。

经划分后,训练集规模为 44,405 条记录、8 个特征,测试集规模为 11,102 条记录、8 个特征。

5.3 Logistic Regression 模型构建

Logistic Regression (逻辑回归)是一种经典的线性分类模型,可作为一种概率型分类器,其结构简单、训练速度快,作为实验的**基准模型 (Baseline)**。模型通过 Sigmoid 函数将线性组合输出映射至 (0,1) 区间,得到样本属于正类的概率估计:

$$P(Y = 1 | \mathbf{X}) = \frac{1}{1 + e^{-z}}$$

其中, $z = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_8 x_8$ 为特征的线性组合, β_0 为截距项, β_i ($i = 1, 2, \dots, 8$) 为各特征的回归系数,其符号与大小直接反映了各特征对复购概率的影响方向与强度, x_i 为第 i 个输入特征。Sigmoid 函数 $\sigma(z) = \frac{1}{1 + e^{-z}}$ 将任意实数值压缩至 (0,1) 区间,其输出为样本属于正类(复购用户)的概率。

模型参数通过极大似然估计进行求解。给定训练数据集 $\{(\mathbf{X}^{(i)}, y^{(i)})\}_{i=1}^N$, 逻辑回归的对数似然函数为:

$$\ell(\boldsymbol{\beta}) = \sum_{i=1}^N [y^{(i)} \log P(Y = 1 | \mathbf{X}^{(i)}) + (1 - y^{(i)}) \log(1 - P(Y = 1 | \mathbf{X}^{(i)}))]$$

通过梯度下降法最大化对数似然函数，即可估计出最优参数 $\boldsymbol{\beta}^*$ 。分类决策时，通常设定阈值 0.5：若 $P(Y = 1 | \mathbf{X}) \geq 0.5$ 则预测为正类，否则预测为负类。

5.4 Random Forest 模型构建

Random Forest（随机森林）是一种基于 Bagging（Bootstrap Aggregating）策略的集成学习方法，由 Breiman 于 2001 年提出^[7]。其核心思想是通过 Bootstrap 随机采样构建多棵决策树，最终通过多数投票机制汇总各棵树的预测结果。

随机森林适用于本研究的电商复购预测场景，原因如下：首先，电商用户行为特征之间往往存在复杂的**非线性交互关系**（如购买频次与平均订单金额的联合效应），单棵决策树能够捕捉特征空间的局部非线性结构，而多棵树的集成进一步增强了模型的表达能力；其次，随机森林通过 Bagging 机制有效降低了单棵决策树的**过拟合风险**，在样本量有限的情况下仍能保持较好的泛化性能；再次，随机森林天然支持**特征重要性评估**，能够为业务决策提供可解释的洞察；最后，随机森林对异常值和缺失值具有较强的鲁棒性，适用于经过清洗但仍可能存在噪声的真实业务数据。

对于包含 N 个样本的训练集，随机森林进行 B 轮 Bootstrap 采样：每轮从原始训练集中有放回地随机抽取 N 个样本，形成一个新的训练子集。基于该子集训练一棵决策树，在树的每个节点分裂时，从全部 M 个特征中随机选取 m 个特征（ $m \ll M$ ）作为候选分裂特征。这种双重随机性（样本随机与特征随机）有效降低了单棵决策树之间的相关性，从而提升了集成模型的泛化能力。

对于分类任务，随机森林的最终预测由所有决策树的投票结果决定：

$$\hat{y} = \text{Mode}(T_1(\mathbf{X}), T_2(\mathbf{X}), \dots, T_B(\mathbf{X}))$$

其中， $T_i(\mathbf{X})$ 表示第 i 棵决策树对输入样本 $\mathbf{X}$ 的类别预测， $\text{Mode}(\cdot)$ 表示取众数操作，即选择出现次数最多的类别作为最终预测结果。

5.5 XGBoost 模型构建

XGBoost 是一种基于梯度提升框架的集成学习算法，由 Chen 和 Guestrin 于 2016 年提出^[8]。与随机森林的 Bagging 策略不同，XGBoost 采用 Boosting 策略：按顺序迭代构建多棵决策树，每棵新树拟合前面所有树的预测残差，逐步减小整体预测误差。

XGBoost 在电商复购预测中的优势体现在：其一，通过二阶泰勒展开近似损失函数，优化效率高于传统梯度提升算法；其二，内置处理缺失值的机制，自动学习缺失值的最优分裂方向；其三，通过 `scale_pos_weight` 参数可灵活调整正负样本权重，适用于本研究的极度不平衡场景。

XGBoost 在第 t 轮迭代时的目标函数由损失函数与正则化项两部分组成：

$$\text{Obj}^{(t)} = \sum_{i=1}^N L(y^{(i)}, \hat{y}_i^{(t-1)} + f_t(\mathbf{X}^{(i)})) + \Omega(f_t)$$

其中， $L(y, \hat{y})$ 为损失函数，衡量预测值与真实值之间的差异，本研究采用对数损失（Log Loss）作为分类任务的损失函数； $\hat{y}_i^{(t-1)}$ 为前 $t-1$ 棵树对第 i 个样本的累计预测值； f_t 为第 t 棵新树； $\Omega(f_t)$ 为正则化项，用于控制模型复杂度，其定义为：

$$\Omega(f_t) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2$$

其中， T 为叶子节点数量， w_j 为第 j 个叶子节点的权重， γ 和 λ 为正则化超参数。正则化项的引入使得 XGBoost 在优化预测精度的同时，有效抑制模型过拟合，提升泛化能力。

5.6 参数优化设计与实现

为充分挖掘各模型的性能潜力，本研究采用 **GridSearchCV**^[9] 进行网格搜索参数优化。网格搜索的原理是：对于给定的超参数取值范围，穷举所有可能的参数组合，通过交叉验证评估每组参数下的模型性能，最终选择使验证集评价指标最优的参数组合。

对于 Logistic Regression 模型，网格搜索的参数空间为：正则化强度 $C \in \{0.01, 0.1, 1, 10\}$ 。参数 C 控制正则化强度与模型复杂度的权衡， C 值越小正则化越强，模型越简单但可能欠拟合； C 值越大正则化越弱，模型越复杂但可能过拟合。采用 **5 折交叉验证**，以 F1-score 作为评价指标，在极度不平衡数据下 F1-score 能够综合反映精确率与召回率的表现。

对于 Random Forest 模型，网格搜索的参数空间包括：`n_estimators`（决策树数量）、`max_depth`（树的最大深度）和 `min_samples_split`（节点分裂所需最小样本数）。




图 5-2 RF 参数搜索热力图

图 5-2 展示了不同参数组合下的模型性能热力图。从图中可以观察到，决策树数量与最大深度的交互效应显著：当树的数量较少时，增加 `max_depth` 能够明显提升模型性能；但当树的数量达到一定程度后，`max_depth` 的影响趋于平缓，表明模型已具备足够的表达能力。`min_samples_split` 参数则控制着树的生长粒度，较大的取值限制树的过度生长，有助于抑制过拟合。综合热力图分析，最终选择使验证集 F1-score 最优的参数组合作为 Random Forest 的参数。

对于 XGBoost 模型，网格搜索的参数空间包括：`n_estimators`（迭代轮数）、`max_depth`（树的最大深度）和 `learning_rate`（学习率）。




图 5-3 XGBoost 参数搜索热力图

图 5-3 展示了 XGBoost 参数搜索热力图。从图中可以分析各参数的作用机制：`max_depth` 控制单棵树的复杂度，较大的 `max_depth` 使模型能够学习更复杂的特征交互，但也增加了过拟合风险；`learning_rate` 控制每棵树的贡献权重，较小的学习率需要配合更多的迭代轮数，但通常能获得更稳定的收敛效果；`n_estimators` 决定迭代次数，与学习率存在明显的交互关系——低学习率下需要更多轮数

才能达到相同的训练效果。从热力图中可以识别出性能较优的参数区域，最终选取验证集表现最佳的参数组合。

参数优化的最终选择依据为：在 5 折交叉验证下，使 F1-score 最大化的参数组合。F1-score 作为调和平均数，能够在精确率与召回率之间取得平衡，适合本研究中正负样本极度不平衡的分类场景。

6. 结果评估与比较

6.1 评价指标说明

为全面评估三种模型在电商用户复购预测任务中的性能，本研究选取了五项常用分类评价指标：准确率（Accuracy）、精确率（Precision）、召回率（Recall）、F1 值（F1-score）和 AUC（Area Under ROC Curve）。

准确率衡量模型整体预测正确的比例，计算公式为：

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

精确率反映模型预测为正类样本中实际为正类的比例：

$$\text{Precision} = \frac{TP}{TP + FP}$$

召回率表示实际正类样本中被模型正确识别的比例：

$$\text{Recall} = \frac{TP}{TP + FN}$$

F1 值为精确率与召回率的调和平均数：

$$\text{F1} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

其中， TP 表示实际复购且被正确预测为复购的用户数； TN 表示实际未复购且被正确预测为未复购的用户数； FP 表示实际未复购但被错误预测为复购的用户数； FN 表示实际复购但被错误预测为未复购的用户数。

AUC 为 ROC 曲线下的面积，取值范围为 [0,1]，用于衡量模型区分正负样本的综合能力，AUC 越接近 1 表示模型区分能力越强。

6.2 三模型结果比较

三种模型在测试集上的性能表现如表 6-1 所示。

表 6-1 三模型评估结果比较

评价指标	Logistic Regression	Random Forest	XGBoost
Accuracy	0.6847	0.8530	0.7419
Precision	0.0124	0.0143	0.0128
Recall	0.3233	0.1654	0.2707
F1-score	0.0240	0.0263	0.0245
AUC	0.5408	0.5155	0.5041

从表 6-1 可以观察到，三种模型的各项指标普遍偏低。以下从数据分布、特征空间和任务本质三个维度对结果进行深层原因剖析。

(1) 类别极度不平衡的制约

本研究面临的核心挑战在于正负样本比例高达 82.7:1 的极度不平衡分布。在这一条件下，即使采用 `class_weight='balanced'` 和 `scale_pos_weight` 等加权策略，模型也难以从有限正样本中提炼稳定的判别模式。具体表现为：Random Forest 虽然通过 Bagging 集成获得了 0.8530 的较高准确率，但其召回率仅为 0.1654，说明模型本质上采取了"保守策略"，将大多数样本预测为负类以换取整体准确率的提升，却牺牲了对复购用户的识别能力。Logistic Regression 召回率相对较高（0.3233），得益于其线性决策边界的简洁性，但受限于线性假设，无法挖掘更深层次的非线性关系。

(2) 精确率偏低的分析

三种模型的精确率均处于极低水平（0.0124 至 0.0143）。在 82.7:1 的先验比例下，即使模型将负类误判率控制在 1%，其产生的假正例数量也将接近真实正样本总量。因此，精确率的低下并非模型性能缺陷的直接反映，而是类别不平衡条件下“基数效应”的结果。

(3) AUC 接近随机水平的解释

三项 AUC 值（0.5041 至 0.5408）均仅略高于随机猜测水平（0.5）。AUC 衡量的是模型将随机抽取的正样本排在随机抽取的负样本之前的概率，在正负样本比例悬殊时，AUC 对少数类的区分能力并不敏感。此外，复购决策本质上受用户心理偏好、竞品动态、宏观经济环境等大量不可观测因素影响，这些"未观测异质性"导致用户复购行为具有高度随机性，因此难以达到理想的区分度。




图 6-1 混淆矩阵

从混淆矩阵可以分析出三种模型的决策差异。Logistic Regression 将 3411 个实际未复购用户误判为复购（FP），同时将 90 个实际复购用户误判为未复购（FN），其召回率最高（0.3233）源于对正类样本相对积极的识别策略，但代价是产生了大量假正例。Random

Forest 的 FP 仅为 1521，但 FN 高达 111，意味着在 133 个实际复购用户中仅正确识别 22 人，超过 83% 的复购用户被漏报，这直接解释了其召回率最低（0.1654）的原因——模型过于保守，倾向于将样本预测为负类以换取整体准确率的提升。XGBoost 的 FP 为 2768，FN 为 97，表现介于两者之间。

上述结果普遍偏低的根本原因在于类别极度不平衡的制约。此外，在负类基数极大的条件下，即使误判率极低，产生的假正例数量也足以严重稀释精确率。

6.3 ROC 曲线和 PR 曲线分析




图 6-2 ROC 曲线

图 6-2 展示了三种模型的 ROC 曲线。从图中可以观察到，三条 ROC 曲线均较为贴近随机猜测线，这与 AUC 值接近 0.5 的现象一致。

ROC 曲线的纵轴为真正例率（TPR），横轴为假正例率（FPR），当负样本基数极大时，FPR 的分母近似于常数，导致 ROC 曲线对模型在负样本中的误判行为不敏感。这一特性使得 ROC 曲线在 82.7:1 的类别比例下难以真实反映模型的区分能力，也解释了为何 AUC 值未能有效区分三种模型的性能差异。




图 6-3 Precision-Recall 曲线

图 6-3 展示了三种模型的 Precision-Recall (PR) 曲线。与 ROC 曲线相比, PR 曲线在正负样本极度不平衡的场景下能够更敏感地反映模型对正类样本的识别性能。

从图 6-3 可以观察到, 三种模型的 PR 曲线均呈现快速下降后趋于平缓的形态。在召回率较低的区域, 精确率相对较高, 但随着召回率的提升, 精确率急剧下降。这一现象揭示了复购预测中"覆盖面"与"精准度"之间的矛盾: 用户是否复购受促销时机、竞品价格、个人收入变化等大量不可预测因素驱动, 历史交易行为仅能提供部分信息。

6.4 特征重要性分析




图 6-4 Random Forest 特征重要性

图 6-4 展示了 Random Forest 模型的特征重要性排序结果。从图中可以观察到，各特征的重要性排序如下： $\text{avg_order_value} > \text{total_spending} > \text{purchase_interval} > \text{purchase_frequency} > \text{avg_delivery_days} > \text{favorite_category} > \text{avg_installments} > \text{favorite_payment}$ 。

排名前三的特征具有明确的业务解释： avg_order_value 位居首位，表明用户的单次消费水平是预测其是否会复购的最强信号。 total_spending 位列第二，综合反映了用户与平台的累计交易。 purchase_interval 排名第三，刻画了用户的购买周期规律。

然而，特征重要性分析也揭示了模型面临的"信号强度不足"困境：即使是最重要的 avg_order_value ，其重要性值也未形成对次要特征的显著优势，且所有特征的重要性值分布较为分散。这表明各特征对复购预测的贡献相对均衡，但均未能提供足够强的判别信号，呈现出"多因素弱效应"的分布模式。




图 6-5 XGBoost 特征重要性

图 6-5 展示了 XGBoost 模型的特征重要性排序结果。从图 6-4 可以观察到，XGBoost 的特征重要性排序与 Random Forest 存在一定差异，但核心驱动因素保持一致： avg_order_value (0.202974) > total_spending (0.174742) > purchase_interval (0.168260) > $\text{purchase_frequency}$ (0.150183) > avg_delivery_days (0.118645) > favorite_category (0.095089) > avg_installments (0.061055) > favorite_payment (0.029053)。

特征重要性的一致性与差异性共同说明：尽管模型算法不同，但它们从数据中提取到的核心信号是相似的，无论采用何种模型，当输入特征的信息含量有限时，输出预测性能必然受到制约。

7. 结论与讨论

7.1 研究结论

本研究基于 Kaggle 平台 Olist Brazilian E-Commerce Dataset，围绕电商用户行为分析与复购预测问题，系统性地完成了**数据预处理、数据仓库设计、可视化分析、用户画像构建及模型建立**等完整的数据挖掘流程。

在数据工程层面，本研究对 6 张核心业务表进行了系统的清洗与集成，构建了包含时间、客户、商品、支付四个维度表与订单事实表的星型数据仓库，为 OLAP 多维分析提供了规范的数据基础。在特征工程阶段，从历史窗口中提取了 8 项用户行为特征，最终形成包含 55,507 条用户记录、10 个字段的建模数据集。

在用户分析层面，基于 RFM 模型结合 KMeans 聚类算法将用户划分为沉睡用户（37.44%）、新客与潜力活跃用户（59.44%）、高频次用户（3.10%）及大额客单用户（0.03%）四类群体，揭示了平台用户结构的严重分化——超过 96% 的用户仅完成单次购买，复购率极低。

在模型预测层面，分别采用 Logistic Regression、Random Forest 和 XGBoost 建立复购预测模型。实验结果表明，Logistic Regression 召回率最高（0.3233），在识别潜在复购用户方面表现最优；Random Forest 准确率最高（0.8530），但对正类样本的识别能力最弱；XGBoost 各项指标处于中间水平。特征重要性分析揭示，平均订单金额、总消费金额与购买间隔是影响用户复购决策的核心驱动因素。

7.2 局限性分析

本研究存在以下几方面局限性。

(1).样本类别极度不平衡。建模数据集中复购用户仅 663 人，占比约 1.19%，而未复购用户高达 54,844 人。尽管采用了 `class_weight` 和 `scale_pos_weight` 等加权策略，模型仍难以从海量负样本中有效学习正样本的判别模式，导致召回率和 F1 值普遍偏低，AUC 仅略高于随机水平。

(2).特征维度相对有限。本研究仅提取了 8 项用户行为特征，未纳入浏览行为、加购行为、收藏行为、评价行为等更丰富的用户互动数据，也未考虑商品评论情感、季节性因素、促销活动等外部变量，特征空间的覆盖度不足可能限制了模型的表达能力。

(3).时间跨度有限。历史窗口约 18 个月，预测窗口为 6 个月，对于捕捉用户的长期消费周期与生命周期演变可能不够充分。此外，数据集时间截止于 2018 年，未能反映近年来电商消费模式的变迁。

参考文献

- [1] SUN Y. Research on customer lifetime value based on machine learning algorithms and customer relationship management analysis model[J]. Heliyon, 2023, 9(2): e13472.
- [2] KIMBALL R, ROSS M. The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling[M]. 3rd ed. Hoboken: John Wiley & Sons, 2013.
- [3] CHAUDHURI S, DAYAL U. An overview of data warehousing and OLAP technology[J]. ACM SIGMOD Record, 1997, 26(1): 65-74.
- [4] HUGHES A M. Strategic Database Marketing[M]. Chicago: NTC Business Books, 1994.
- [5] SYAKUR M A, KHOTIMAH B K, ROCHMAN E M S, et al. Integration k-means clustering method and elbow method for identification of the best customer profile cluster[C]//IOP Conference Series: Materials Science and Engineering. Bristol: IOP Publishing, 2018, 336: 012017.
- [6] PEDREGOSA F, VAROQUAUX G, GRAMFORT A, et al. Scikit-learn: Machine learning in Python[J]. Journal of Machine Learning Research, 2011, 12: 2825-2830.
- [7] BREIMAN L. Random forests[J]. Machine Learning, 2001, 45(1): 5-32.
- [8] CHEN T, GUESTRIN C. XGBoost: A scalable tree boosting system[C]//Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. San Francisco: ACM, 2016: 785-794.
- [9] ANDESPA R, SADIK K, SUHAENI C, et al. Evaluating random forest and XGBoost for bank customer churn prediction on imbalanced data using SMOTE and SMOTE-ENN[J]. Media Statistika, 2025, 18(1): 25-36.

附录

代码详见附件。